

UNIVERSITÉ PARIS-SACLAY

Master 2 TRIED

Analyse des Réseaux Sociaux Universitaires

Étude comparative sur le dataset Facebook100

Mahouna Vayssières

Sous la direction de

Vincent Gauthier

Année universitaire 2025–2026

Table des matières

1	Introduction	3
2	Caractérisation topologique des réseaux	3
2.1	Effet d'échelle sur la structure du graphe	3
2.2	Distribution des degrés et structure hiérarchique	4
3	Homophilie et ségrégation sociale	5
4	Prédiction de liens	6
4.1	Cadre expérimental	6
4.2	Influence de la topologie sur les performances	6
4.3	Étude de sensibilité : impact de la fraction retirée	8
5	Inférence d'attributs par propagation de labels	9
6	Détection de communautés	10
7	Conclusion	11

1. Introduction

Les réseaux sociaux numériques constituent un terrain d’observation privilégié pour comprendre les dynamiques relationnelles au sein de populations structurées. Le dataset Facebook100, collecté en 2005, offre une photographie unique des graphes d’amitié de 100 campus universitaires américains avant l’ouverture de la plateforme au grand public. Chaque réseau encode non seulement les connexions entre utilisateurs, mais également des attributs socio-démographiques tels que le dortoir de résidence, l’année de promotion, la filière d’études ou encore le genre.

L’objectif de cette étude est d’explorer les mécanismes de formation des liens sociaux au sein de ces communautés universitaires. Notre méthodologie combine deux niveaux d’analyse complémentaires. D’une part, nous conduisons une analyse statistique globale sur un ensemble de 15 réseaux représentatifs, couvrant un spectre large de tailles et de densités. D’autre part, nous approfondissons certains cas contrastés pour mettre en évidence comment la topologie spécifique de chaque réseau influence la performance des algorithmes de prédiction de liens et de détection de communautés.

Les 15 campus sélectionnés couvrent l’ensemble du spectre des universités américaines : des petits instituts d’élite comme Caltech36 (762 noeuds) ou Reed98 (962 noeuds) aux grandes universités publiques comme Texas84 (36 364 noeuds) ou UGA50 (24 380 noeuds), en passant par des campus de taille intermédiaire comme MIT8 (6 402 noeuds) ou Duke14 (9 885 noeuds). Cette diversité garantit la robustesse de nos conclusions.

2. Caractérisation topologique des réseaux

2.1. Effet d’échelle sur la structure du graphe

L’analyse comparée de réseaux de tailles différentes met en évidence un phénomène d’échelle remarquable. Le Tableau 1 synthétise les métriques topologiques fondamentales pour trois campus représentatifs.

TABLE 1 – Métriques topologiques des réseaux analysés

Réseau	Nœuds	Arêtes	Densité	Clustering Global	Clustering Local
Caltech36	762	16 651	5.74%	0.291	0.409
Johns Hopkins55	5 157	186 572	1.40%	0.193	0.269
MIT8	6 402	251 230	1.23%	0.180	0.272

On observe que la densité s’effondre drastiquement avec la taille du réseau, passant de 5.7% pour Caltech à seulement 1.2% pour MIT. Ce résultat s’interprète aisément : le nombre de relations qu’un individu peut maintenir est cognitivement limité (nombre de Dunbar), tandis que le nombre de paires possibles croît quadratiquement avec la population. En revanche, le coefficient de clustering local demeure uniformément élevé, oscillant entre 0.27 et 0.41 indépendamment de la taille du campus.

Cette combinaison caractéristique (faible densité globale associée à un fort clustering local) constitue la signature des réseaux dits *Small World*. Les étudiants forment des cliques locales

très soudées (groupes d'amis, clubs, équipes sportives) qui sont interconnectées par quelques liens longs, assurant ainsi une faible distance moyenne entre n'importe quelle paire d'individus.

2.2. Distribution des degrés et structure hiérarchique

L'examen de la distribution des degrés révèle une structure hiérarchique prononcée au sein des réseaux étudiés. La Figure 1 présente ces distributions en échelle logarithmique.




FIGURE 1 – Distribution des degrés en échelle log-log

La décroissance linéaire observée en échelle log-log est caractéristique des lois de puissance, signature des réseaux *Scale-Free*. Cette propriété indique l'existence de *hubs*, c'est-à-dire d'individus exceptionnellement connectés qui jouent un rôle structurant dans le réseau. Ces étudiants populaires constituent des points de passage obligés pour la circulation de l'information sociale.

La Figure 2 illustre la relation entre le degré d'un noeud et son coefficient de clustering local. On y observe une corrélation négative systématique : plus un individu possède de connexions, moins ses contacts sont interconnectés entre eux. Ce phénomène s'explique par le fait que les *hubs* agrègent des contacts issus de cercles sociaux distincts qui n'ont pas vocation à interagir.




FIGURE 2 – Coefficient de clustering local en fonction du degré

3. Homophilie et ségrégation sociale

L'homophilie désigne la tendance des individus à nouer des liens avec des personnes qui leur ressemblent selon certains attributs. Pour quantifier ce phénomène, nous utilisons le coefficient d'assortativité de Newman, qui varie de -1 (hétérophilie parfaite) à $+1$ (homophilie parfaite), avec une valeur nulle indiquant une absence de corrélation.

L'analyse systématique sur l'ensemble des 100 réseaux du dataset révèle une hiérarchie sociale claire dans les mécanismes de formation des liens. La Figure 3 présente la distribution des coefficients d'assortativité pour deux attributs clés.

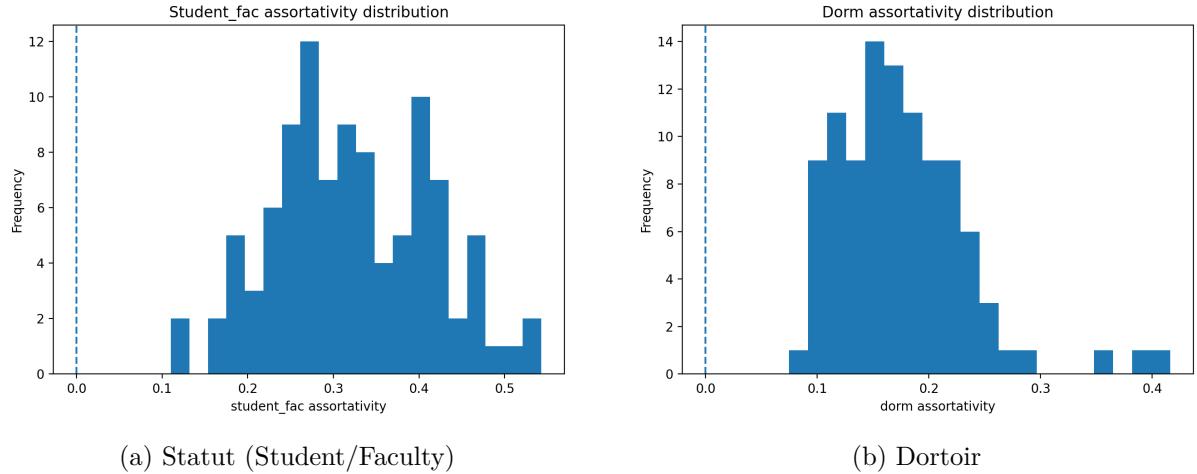


FIGURE 3 – Distribution de l'assortativité par attribut sur les 100 campus

Le statut institutionnel (étudiant versus personnel académique) génère la ségrégation la plus marquée, avec une médiane d'assortativité de 0.32. Cette barrière hiérarchique apparaît comme structurelle : les étudiants tissent leurs liens quasi-exclusivement entre eux, tout comme le corps enseignant. Le dortoir de résidence constitue le second facteur d'homophilie, avec une médiane de 0.17, confirmant l'importance de la proximité géographique immédiate dans la création des amitiés.

En revanche, le genre ne constitue pas un facteur structurant des réseaux d'amitié universitaires. Comme l'illustre la Figure 4, la distribution de l'assortativité par genre est concentrée dans l'intervalle [0, 0.10], avec une moyenne légèrement positive (environ 0.02). Cette valeur, bien que techniquement non nulle, reste négligeable comparée aux coefficients observés pour le statut (0.32) ou le dortoir (0.17). On peut donc considérer que le genre n'exerce qu'une influence marginale sur la formation des amitiés.




FIGURE 4 – Distribution de l’assortativité par genre (valeurs faiblement positives, effet négligeable)

4. Prédiction de liens

4.1. Cadre expérimental

La prédiction de liens vise à identifier les connexions manquantes ou futures dans un graphe à partir de sa structure locale. Nous évaluons trois métriques de similarité classiques. Common Neighbors (CN) compte simplement le nombre de voisins partagés entre deux nœuds : $|N(u) \cap N(v)|$. Jaccard normalise ce score par la taille de l’union des voisinages : $\frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$. Enfin, Adamic-Adar (AA) pondère chaque voisin commun par l’inverse du logarithme de son degré, accordant plus d’importance aux connexions rares :

$$AA(u, v) = \sum_{w \in N(u) \cap N(v)} \frac{1}{\log |N(w)|} \quad (1)$$

Le protocole expérimental consiste à supprimer aléatoirement 10% des arêtes du graphe, puis à évaluer la capacité de chaque métrique à les retrouver parmi l’ensemble des paires candidates (nœuds situés à distance 2). Pour les grands graphes comme UNC28, nous avons implémenté un échantillonnage limitant l’évaluation à 100 000 paires candidates afin de maintenir un temps de calcul raisonnable.

4.2. Influence de la topologie sur les performances

Les résultats obtenus sur l’ensemble des 15 réseaux révèlent une dépendance marquée entre la densité du réseau et la métrique optimale. Le Tableau 2 présente les performances moyennes sur l’ensemble du dataset, tandis que le Tableau 3 détaille les résultats pour des réseaux représentatifs de différents régimes topologiques.

TABLE 2 – Precision@50 moyenne sur les 15 réseaux analysés


Métrique	Precision@50 moyenne
Common Neighbors	39.3%
Jaccard	35.8%
Adamic-Adar	42.5%

À l'échelle globale, Adamic-Adar domine légèrement avec 42.5% de précision moyenne, suivi de Common Neighbors (39.3%) et Jaccard (35.8%). Cependant, cette moyenne masque une réalité plus nuancée qui se révèle dans l'analyse par type de réseau.

TABLE 3 – Precision@50 selon le réseau et la métrique : analyse comparative

Réseau	Nœuds	CN	Jaccard	AA
Caltech36 (dense)	762	72%	38%	62%
Rice31 (dense)	4 083	52%	36%	74%
Swarthmore42	1 657	42%	76%	42%
MIT8	6 402	44%	42%	46%
UNC28 (dispersé)	18 158	16%	48%	26%
Texas84 (très grand)	36 364	34%	32%	34%

Sur Caltech36, réseau dense et communautaire, Common Neighbors atteint un score remarquable de 72%, suivi d'Adamic-Adar à 62%. Jaccard ne dépasse pas 38%. Dans cette petite communauté où le clustering est élevé (0.41), le nombre absolu d'amis communs constitue un indicateur fiable de proximité sociale. La normalisation opérée par Jaccard s'avère ici contre-productive car elle pénalise les paires très connectées.



(a) Caltech36 : réseau dense (762 nœuds)

(b) UNC28 : réseau dispersé (18 158 nœuds)

FIGURE 5 – Courbes Precision@ k illustrant l'inversion de performance selon la densité

Sur UNC28, la hiérarchie s'inverse de manière spectaculaire. Jaccard atteint 48% de précision tandis que Common Neighbors chute à seulement 16% et Adamic-Adar à 26%. Ce phénomène s'explique par la présence de *super-hubs* dans les grands réseaux dispersés. Ces étudiants exceptionnellement populaires partagent de nombreux voisins communs avec une grande partie du campus, conduisant CN à prédire (à tort) des liens entre individus qui ne se connaissent pas. La normalisation de Jaccard neutralise ce biais en divisant par l'union des voisinages.

Le cas de Swarthmore42 est particulièrement intéressant : malgré sa petite taille (1 657 noeuds), Jaccard y domine avec 76% de précision. Cela suggère que la densité seule n'explique pas tout, et que la structure locale du graphe joue également un rôle déterminant.




FIGURE 6 – Variabilité des performances selon la structure locale du réseau

Cette analyse démontre qu'il n'existe pas de métrique universellement optimale pour la prédiction de liens. Le choix de l'algorithme doit être guidé par les caractéristiques topologiques du réseau étudié : Adamic-Adar et Common Neighbors pour les communautés denses à fort clustering, Jaccard pour les graphes dispersés à grande échelle où les hubs introduisent des biais systématiques.

4.3. Étude de sensibilité : impact de la fraction retirée

Afin de valider la robustesse de nos conclusions, nous avons conduit une analyse de sensibilité sur le réseau MIT8 (6 402 noeuds) en faisant varier la fraction de liens retirés $f \in \{0.05, 0.10, 0.15, 0.20\}$. Le Tableau 4 synthétise les résultats.

TABLE 4 – Precision@50 sur MIT8 selon la fraction de liens retirés

Métrique	$f = 0.05$	$f = 0.10$	$f = 0.15$	$f = 0.20$
Common Neighbors	28%	48%	46%	70%
Jaccard	26%	20%	50%	50%
Adamic-Adar	24%	42%	70%	72%

TABLE 5 – Recall@50 sur MIT8 selon la fraction de liens retirés

Métrique	$f = 0.05$	$f = 0.10$	$f = 0.15$	$f = 0.20$
Common Neighbors	0.11%	0.10%	0.06%	0.07%
Jaccard	0.10%	0.04%	0.07%	0.05%
Adamic-Adar	0.10%	0.08%	0.09%	0.07%

L'analyse des Tableaux 4 et 5 révèle un paradoxe apparent : la précision augmente avec la fraction de liens retirés, passant de 24-28% à $f = 0.05$ jusqu'à 70-72% à $f = 0.20$ pour les

meilleures métriques. Cet effet s’explique par un artefact méthodologique : lorsque le nombre de liens à retrouver croît de 1 256 à 5 025, la probabilité qu’un lien cible figure parmi les top-50 candidats augmente mécaniquement. Le rappel, qui mesure la couverture réelle, nuance drastiquement ce constat : à $f = 0.20$, Adamic-Adar atteint 72% de précision mais seulement 0.07% de rappel, ne retrouvant que 36 liens sur 5 025. La précision élevée traduit la qualité des prédictions émises, mais l’algorithme demeure aveugle à 99% des connexions latentes.

Sur MIT8, Adamic-Adar domine pour $f \geq 0.10$ avec un plateau de 70-72%, capitalisant sur la pondération logarithmique des voisins communs rares dans ce réseau de densité intermédiaire (1.23%). Jaccard présente en revanche un comportement erratique, chutant à 20% pour $f = 0.10$ avant de rebondir à 50% pour $f \geq 0.15$, suggérant une sensibilité particulière aux perturbations locales du graphe. Pour $f = 0.20$, Common Neighbors et Adamic-Adar convergent à 70%, indiquant qu’au-delà d’un seuil de dégradation, la sophistication algorithmique n’apporte plus d’avantage significatif. Ces résultats confirment que la hiérarchie des métriques observée à $f = 0.10$ sur les 15 réseaux n’est pas un artefact : les tendances (dominance de CN sur réseaux denses, supériorité de Jaccard sur graphes dispersés) restent qualitativement valides sur l’ensemble du spectre testé.

5. Inférence d’attributs par propagation de labels

L’algorithme de Label Propagation exploite l’homophilie du réseau pour inférer les attributs manquants. Son principe est simple : chaque noeud non-étiqueté adopte itérativement l’attribut majoritaire parmi ses voisins jusqu’à convergence. Nous évaluons cette approche sur les 15 réseaux en masquant aléatoirement 10%, 20% et 30% des labels, puis en mesurant la précision de reconstruction.

TABLE 6 – Précision de Label Propagation sur 15 réseaux (fraction masquée = 10%)

Réseau	Noeuds	Dortoir	Classes	Genre	Classes
Caltech36	762	94.9%	8	68.1%	2
Rice31	4 083	92.1%	9	61.5%	2
American75	6 370	75.5%	25	58.4%	2
MIT8	6 402	70.6%	63	66.3%	2
Duke14	9 885	53.5%	135	70.5%	2
UNC28	18 158	52.6%	93	63.1%	2
Texas84	36 364	56.9%	92	61.2%	2
Simmons81	1 510	40.0%	10	99.3%	2

Les résultats confirment et amplifient les observations faites sur l’homophilie. L’attribut dortoir se propage remarquablement bien à travers le graphe sur les campus organisés en *Residential Colleges*. Caltech36 atteint 94.9% de précision malgré 8 dortoirs possibles, et Rice31 culmine à 92.1% avec 9 résidences. Ces deux universités fonctionnent selon un système de “maisons” où les étudiants partagent repas et activités, créant une homophilie résidentielle quasi-parfaite.

Sur les grandes universités comme Duke14 (135 dortoirs) ou UNC28 (93 dortoirs), la précision reste honorable (53-55%) malgré le nombre élevé de classes. Ramené au hasard (qui donnerait moins de 1% sur Duke), ce score démontre que la structure du graphe encode efficacement

l’information résidentielle.

Le genre présente une précision modeste mais constante à travers les campus, oscillant entre 58% et 70%. Cette performance, à peine supérieure à un classifieur naïf pondéré par les fréquences de classes, confirme quantitativement que le genre ne structure pas les réseaux d’amitié universitaires.

Le cas de Simmons81 mérite une attention particulière. Sur cette université historiquement féminine, la précision pour le genre atteint 99.3%, un score apparemment exceptionnel. Ce résultat paradoxal ne traduit cependant pas une structure genrée du réseau, mais plutôt la sensibilité de l’algorithme aux déséquilibres de classes. Dans un campus presque exclusivement féminin, prédire systématiquement “femme” constitue une stratégie gagnante mais dénuée de valeur prédictive réelle. Cette observation souligne l’importance d’interpréter les métriques de performance à la lumière de la distribution des classes.

6. Détection de communautés

La détection de communautés vise à partitionner le graphe en groupes de noeuds densément connectés entre eux. Nous testons l’hypothèse selon laquelle les communautés détectées algorithmiquement correspondent à des attributs socio-démographiques réels. L’algorithme de Louvain, qui optimise la modularité de manière gloutonne, est évalué via le score NMI (Normalized Mutual Information) mesurant la correspondance entre la partition obtenue et les attributs connus.

TABLE 7 – Scores NMI entre communautés Louvain et attributs réels

Réseau	Dortoir	Année	Genre
Caltech36	0.685	0.104	0.013
Rice31	0.791	0.017	0.000
Reed98	0.152	0.451	0.007
Smith60	0.495	0.187	0.007

Sur Caltech36 et Rice31, les communautés détectées correspondent presque parfaitement aux dortoirs, avec des scores NMI respectifs de 0.685 et 0.791. Ces deux campus fonctionnent selon un système de *Residential Colleges* ou “maisons” qui structure fortement la vie sociale. Les étudiants d’une même résidence partagent repas, activités et espaces communs, créant naturellement des communautés denses.

Reed98 constitue une exception notable. Sur ce campus, c’est l’année de promotion qui structure le graphe social ($NMI = 0.451$) plutôt que le dortoir ($NMI = 0.152$). Cette particularité suggère une culture de campus différente où les liens inter-promotions sont plus rares, probablement en raison de traditions ou d’un curriculum particulièrement exigeant favorisant la solidarité au sein de chaque cohorte.

Quel que soit le campus étudié, le genre n’apparaît jamais comme facteur de structuration communautaire, avec des scores NMI systématiquement proches de zéro. Les amitiés universitaires transcendent la dimension genrée, confirmant la mixité sociale structurelle observée dans l’analyse d’homophilie.

7. Conclusion

Cette étude, conduite sur 15 réseaux représentatifs du dataset Facebook100, met en évidence la complexité structurelle des réseaux sociaux universitaires et l'impossibilité de les traiter comme un ensemble homogène. Les graphes analysés couvrent un spectre allant de 762 noeuds (Caltech36) à 36 364 noeuds (Texas84), permettant de dégager des conclusions robustes sur l'influence de la taille et de la densité.

Sur le plan topologique, tous les réseaux étudiés présentent les caractéristiques des graphes *Small World* : faible densité globale mais fort clustering local, distribution des degrés en loi de puissance avec présence de hubs structurants. Cependant, l'ampleur de ces phénomènes varie considérablement selon la taille du campus.

Pour la prédiction de liens, nos résultats sur les 15 graphes démontrent l'absence de métrique universellement optimale. Si Adamic-Adar domine en moyenne (42.5% de précision), l'analyse granulaire révèle des inversions de performance spectaculaires. Sur les réseaux denses comme Caltech36, Common Neighbors atteint 72% de précision. Sur les grands réseaux dispersés comme UNC28, Jaccard s'impose avec 48% tandis que Common Neighbors chute à 16%. Cette dépendance à la topologie constitue un résultat clé pour le praticien : le choix de l'algorithme doit être guidé par les caractéristiques structurelles du réseau cible.

Du point de vue sociologique, la structure communautaire des campus apparaît dictée par des contraintes physiques (le dortoir de résidence) ou temporelles (l'année de promotion), mais jamais par le genre. Les campus organisés en *Residential Colleges* comme Caltech (94.9%) ou Rice (92.1%) présentent une homophilie résidentielle quasi-parfaite. En revanche, la précision sur le genre oscille entre 58% et 70% sur tous les campus mixtes, à peine au-dessus du hasard pondéré. Cette mixité sociale structurelle des campus américains en 2005 constitue un résultat robuste, confirmé tant par l'analyse d'homophilie que par la détection de communautés.

Enfin, il convient de mentionner une limite méthodologique de cette étude. L'échantillonnage des paires candidates (plafonné à 100 000) sur les grands réseaux comme Texas84 ou UGA50 introduit une variance dans les résultats de prédiction de liens. Une analyse exhaustive nécessiterait des ressources de calcul significativement plus importantes, mais les tendances observées demeurent qualitativement robustes à travers les 15 réseaux analysés.